

Algorithmes d'optimisation

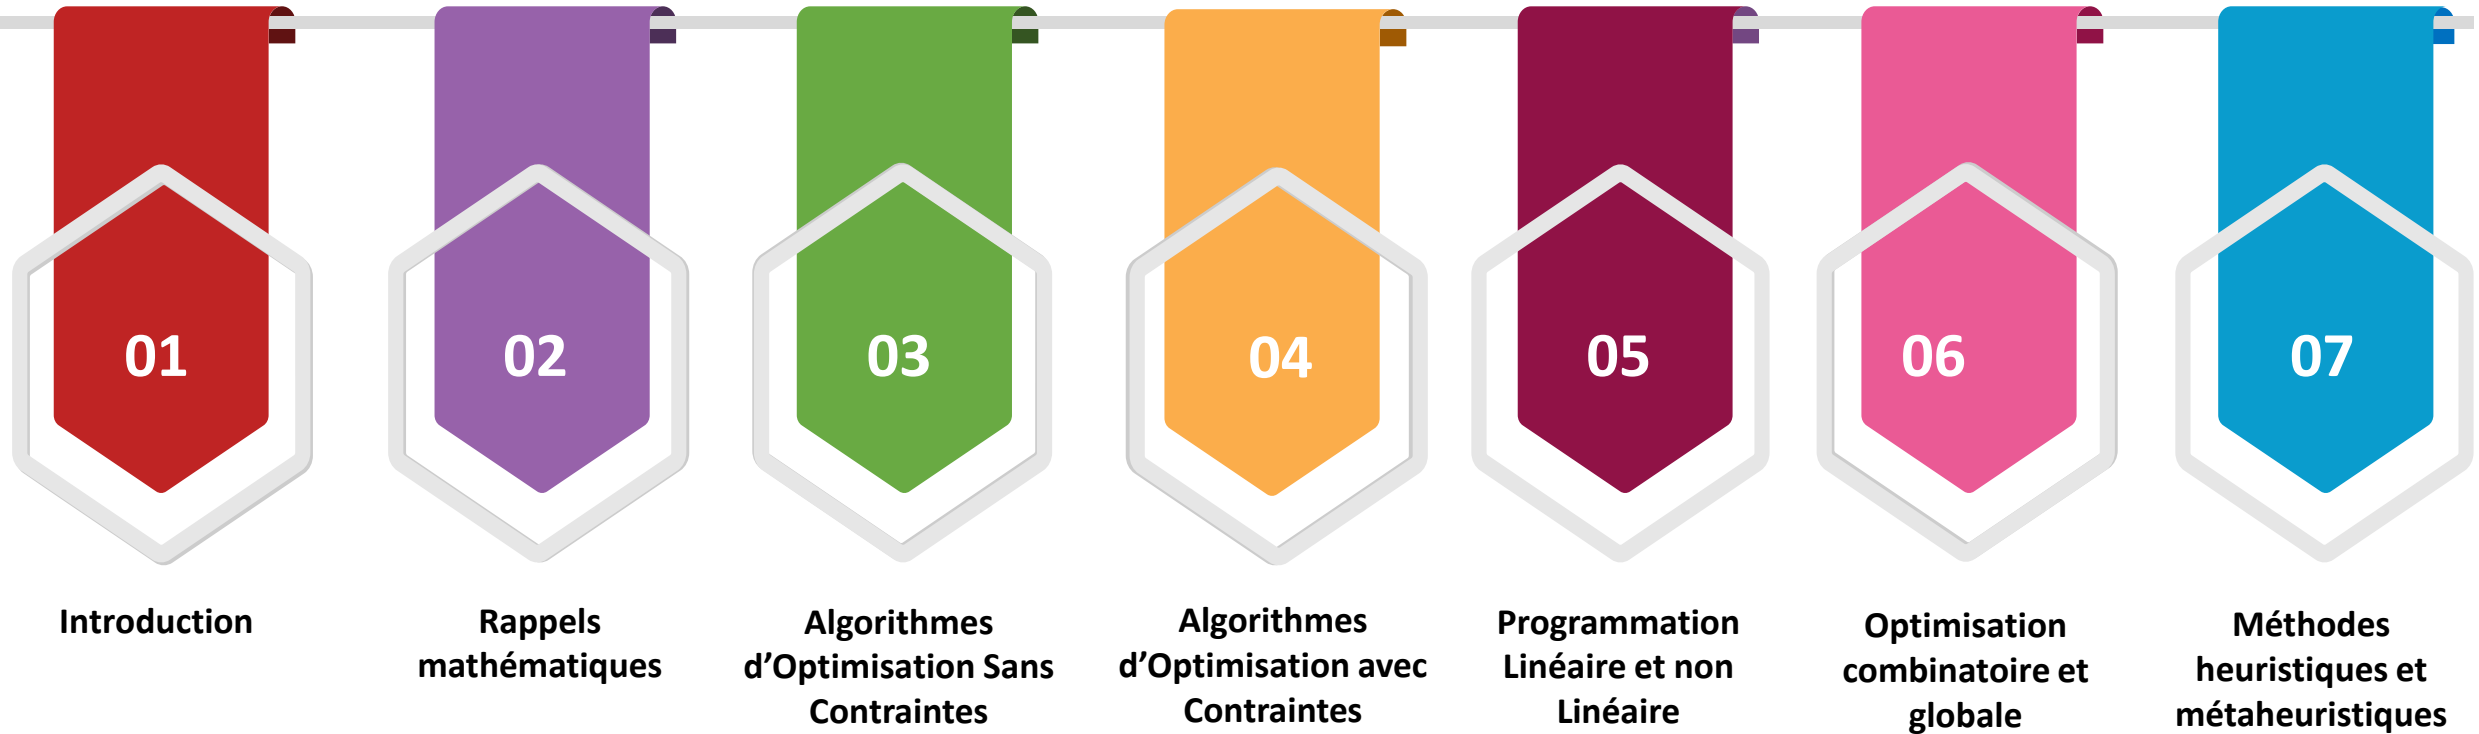
Pr. Faouzia Benabbou (faouzia.benabbou@univh2c.ma)

Département de mathématiques et Informatique

Master Data Science & Big Data

2024-2025

Plan du Module: Algorithmes d'optimisation



Rappels mathématiques

Matrices

■ Matrice Définie +/-

Soit A une matrice carrée réelle de taille $n \times n$.

On dit que A est:

- **Définie positive** si pour tout vecteur $x \in \mathbb{R}^n$, $x^T A x > 0$.
 - **Semi-définie positive** si pour tout vecteur $x \in \mathbb{R}^n$, $x^T A x \geq 0$.
 - **Définie négative** si pour tout vecteur $x \in \mathbb{R}^n$, $x^T A x < 0$.
 - **Semi-définie négative** si pour tout vecteur $x \in \mathbb{R}^n$, $x^T A x \leq 0$.
- $x^T A x$ est appelée la forme **quadratique** ou **l'énergie** d'une matrice.

Matrices

▪ Matrice Définie +/-

- Exemple.

✓ $X=(x,y)$ et $A=\begin{bmatrix} a & b \\ b & c \end{bmatrix}$.

$$x^T A x = (x, y) \begin{bmatrix} a & b \\ b & c \end{bmatrix} (x, y) = ax^2 + 2bxy + cy^2$$

✓ $X=(x,y)$ et $A=\begin{bmatrix} 1 & 6 \\ 6 & -1 \end{bmatrix}$.

$$x^T A x = (x, y) \begin{bmatrix} 1 & 6 \\ 6 & -1 \end{bmatrix} (x, y) = x^2 + 12xy - y^2$$

Matrices

■ Matrice Définie +/-

- **Théorème.** Une matrice symétrique réelle A est définie positive si et seulement si toutes ses **valeurs propres** sont strictement positives.
- **Décomposition de Cholesky.** Si A est symétrique et définie positive, alors elle peut se décomposer sous forme suivante:

$$A = LL^T$$

L une matrice triangulaire inférieure.

Matrices

■ Matrice Définie +/-

- **Critères de détermination.** Il existe plusieurs critères pour déterminer si une matrice symétrique est définie positive.
- Les plus courants sont :
 1. Calculer les **valeurs propres** de la matrice A . Si toutes les valeurs propres sont strictement positives, alors la matrice est définie positive.
 2. Critère de Sylvester. Calculer les **déterminants** de toutes les sous-matrices principales de A . Si tous ces déterminants sont strictement positifs, alors la matrice est définie positive.
 3. Décomposition de **Cholesky**. Si la matrice A admet une décomposition de Cholesky, alors A est définie positive.

Matrices

■ Matrice Définie +/-

- **Critères de détermination.** Ces propriétés sont importantes car elles permettent de déterminer certaines **caractéristiques** de la matrice et de la forme quadratique associée.
- Par exemple :
 - ✓ Les matrices définies positives sont **inversibles**.
 - ✓ Les **valeurs propres** d'une matrice définie positive sont toutes strictement positives.
 - ✓ La matrice **identité** est définie positive.
 - ✓ Une matrice **diagonale** dont tous les éléments diagonaux sont positifs est définie positive.
 - ✓ Une matrice de **covariance** est semi-définie positive.

Matrices

■ Matrice Définie +/-

- **Exemple de matrice DP.** La matrice de **covariance** est un outil important qui permet de :
 - ✓ **Visualiser les relations:** Elle permet de voir rapidement quelles variables sont **corrélées** entre elles et dans quelle direction.
 - ✓ **Réduire la dimensionnalité:** Dans les problèmes avec de nombreuses variables, elle aide à identifier les groupes de variables qui **varient ensemble**, ce qui permet de simplifier l'analyse.
 - ✓ **Analyse en composantes principales (ACP):** Elle est utilisée dans l'ACP pour transformer des variables corrélées en un plus petit nombre de variables non corrélées (réduction de la dimension).
 - ✓ **Modélisation statistique:** Elle est essentielle dans de nombreux modèles statistiques, notamment les modèles gaussiens et les modèles de régression multiple.

Matrices

■ Matrice Définie +/-

● Exemple de covariance.

- ✓ La matrice de covariance se calcule à l'aide de la formule suivante :

$$Cov(x, y) = \Sigma[(x_i - \bar{x})(y_i - \bar{y})] / (n - 1)$$

- ✓ x_i et y_i sont les valeurs individuelles des variables X et Y
- ✓ \bar{x} et \bar{y} sont les moyennes des variables x et y, n est le nombre d'observations.
- ✓ Supposons que nous ayons les données suivantes pour trois variables : la température (T), l'humidité (H) et la consommation d'énergie (E) :

T (°C)	H (%)	E (kWh)	
20	60	150	
25	50	180	
30	70	200	
25	60	176,67	Moyenne

Matrices

■ Matrice Définie +/-


- **Exemple de covariance.**
- La matrice de covariance est donnée par :

	T	H	E
T	25	25	125
H	25	100	100
E	125	100	633,333

- On peut voir par exemple que $\text{Cov}(T,H)=25 \rightarrow$ Légère corrélation positive entre la température et l'humidité alors que $\text{Cov}(T,E)=125 \rightarrow$ forte corrélation positive entre la température et la consommation d'énergie.
- Voir aussi la corrélation de Pearson, qui est normalisée pour être comprise entre -1 et 1.

Convexité


- Dans les problèmes d'optimisation, une notion joue un rôle très important : celle de convexité.
- En effet, pour la plupart des algorithmes, la convergence vers un optimum global ne pourra être démontrée qu'avec des hypothèses de convexité.



Convexité

■ Ensemble convexe

- **Définition.** Soit l'ensemble $C \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$, C est **convexe** si $\forall x, y \in C, \forall \lambda \in [0,1]: \lambda x + (1-\lambda)y \in C$.
- D'un point de vue géométrique, un convexe est donc un ensemble qui, lorsqu'il contient deux points, contient nécessairement le segment les reliant.



A et B non connexe

Convexité

▪ Exemple d'ensemble convexe.

- Un **disque** est convexe, car tout segment reliant deux points du disque reste à l'intérieur.
- Un **triangle** est convexe, car tout segment joignant deux de ses points reste dans le triangle.
- Une forme en **fer à cheval** n'est pas convexe, car il existe des segments reliant deux points de la forme qui sortent de l'ensemble.

Convexité

▪ Ensemble convexe

Théorème. L'image d'un connexe par une fonction continue est un connexe.

Proposition. Soient C, C_1, C_2 des convexes de \mathbb{R}^n , $I, J \subset \mathbb{R}$; on a les propriétés suivantes:

- Si $\lambda_1, \lambda_2 \in \mathbb{R}$, alors $\lambda_1 C_1 + \lambda_2 C_2$ est un convexe de \mathbb{R}^n
- Si $(C_j)_{j \in J}$ est une famille quelconque de convexes de \mathbb{R}^n , alors $\bigcap_{j \in J} C_j$ est un convexe de \mathbb{R}^n .
- Si C est un convexe de \mathbb{R}^n et $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ est une application affine de type $f(x) = Ax + b$ pour $A \in \mathbb{R}^{m \times n}$ et $b \in \mathbb{R}^m$, alors $f(C)$ est un convexe de \mathbb{R}^m .

Convexité

▪ Fonction convexe.

Définition. Soit $C \subset \mathbb{R}^n$ et $f : C \rightarrow \mathbb{R}$. On dit que **f est convexe** si :

- $\forall x, y \in C, \forall \lambda \in [0,1] \ f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$.
- f est strictement convexe si on peut mettre l'inégalité stricte pour $\lambda \in]0, 1[$ et $x \neq y$.
- Une fonction f est dite (strictement) concave si $-f$ est (strictement) convexe.

- L'interprétation géométrique de cette définition est que le graphe d'une fonction convexe est toujours en dessous du segment reliant les points $(x, f(x))$ et $(y, f(y))$.

Convexité

▪ Fonction convexe.

Propriété. Si $f : C \subset \mathbb{R}^n \rightarrow \mathbb{R}$ est deux fois continument dérivable sur C convexe, alors:

- f est convexe si et seulement si $f''(X) \geq 0, \forall X \in C$
- f est concave si $f''(X) \leq 0, \forall X \in C$.
- f est strictement convexe si $f''(X) > 0, \forall X \in C$.

▪ Exemple. $f(x)=x^2$, \mathbb{R} est convexe ,

- f est 2 fois dérivable
- $f''(x)=2>0$, f est convexe

Convexité

- **Fonction convexe.**

Théorème fondamental : Si une fonction f est **convexe** sur un ensemble ouvert convexe $C \subset \mathbb{R}^n$, alors :

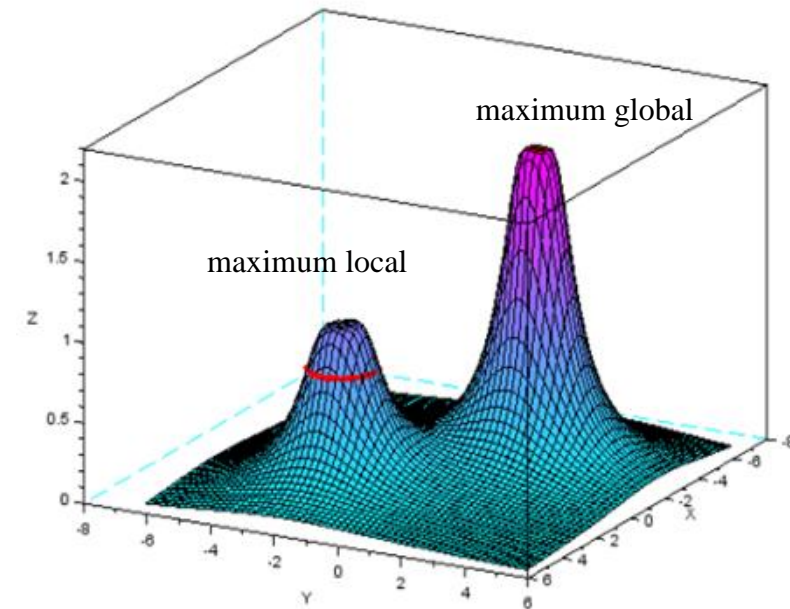

- a) Si f admet en $X_0 \in C$ un **minimum local**, alors f admet en X_0 un minimum **global**.
- b) Si f est de classe \mathbf{C}^1 sur C ; alors si $\nabla f(X_0) = 0$, alors X_0 est un minimum global sur C .

Extremums

- **Définition des Extremums local/ global.** Soit f une fonction définie sur une partie U de \mathbb{R}^n et à valeurs réelles, un point $a \in U$:
 - a est un minimum local (ou relatif) de f s'il existe un voisinage v_a de a ouvert dans U tel que: $f(x) \geq f(a)$ pour tout $x \in v_a$.
 - a est un maximum local (ou relatif) de f s'il existe un voisinage V_a de a ouvert dans U tel que: $f(x) \leq f(a)$ pour tout $x \in v_a$.
 - a est un extremum local si f admet un maximum local ou bien un minimum local en ce point.

Extremums

- **Définition des Extremums local/ global.** Un extremum est dit strict si l'inégalité est stricte, c'est à dire $f(x) > f(a)$, pour tout $x \neq a$.



Extremums

- **Condition d'existence d'un extremum.** L'existence d'un extremum dépend énormément de la fonction en question et du domaine sur lequel on cherche cet optimum.
- Plusieurs théorèmes ont permis de montrer leur existence sous certaines conditions.
- Ces théorèmes sont cruciaux en optimisation, car ils fournissent une condition **suffisante ou suffisante** pour l'existence d'une solution optimale pour de nombreux problèmes.

Extremums

Cas des fonctions d'une variable réelle.

- **Théorème de Fermat (condition nécessaire du premier ordre).**
Si une fonction f est dérivable en un point x_0 et que x_0 est un extremum local de f , alors le gradient de f en x_0 est nul : $\nabla f(x_0) = 0$.
- Autrement dit, si a est un extremum local alors a est un point critique.
- La réciproque n'est pas toujours vraie. Par exemple, pour $f: x \rightarrow x^3$, le point $a = 0$ est un point critique, mais ce n'est ni un maximum local ni un minimum local (a est un point d'inflexion).

Extremums

Cas des fonctions d'une variable réelle.

- **Théorème (Conditions suffisantes du second ordre).** Soit f une fonction deux fois dérivable sur un intervalle ouvert I . Soit a un point de I tel que $f'(a) = 0$ (c'est-à-dire, a est un point critique), alors :
 - Si $f''(a) > 0$, alors f admet un minimum local strict en a .
 - Si $f''(a) < 0$, alors f admet un maximum local strict en a .
 - Si $f''(a) = 0$, alors on ne peut pas conclure à l'aide de ce théorème. Il faut approfondir l'étude (en utilisant des dérivées d'ordre supérieur ou d'autres méthodes).

Extremums

Cas des fonctions d'une variable réelle.

- **Théorème de Weierstrass.** Soient K un ensemble **compact** (fermé et borné) non vide de \mathbb{R}^n et $f : K \rightarrow \mathbb{R}$ une fonction **continue** sur K , alors f admet est bornée et atteint ses bornes sur K .
- Autrement il existe toujours un point dans cet intervalle où la fonction atteint sa valeur maximale, et un autre point où elle atteint sa valeur minimale.
- C'est à dire, il existe a^* tel que : $f(a^*) = \min_{x \in K} f(x)$,
ou $f(a^*) = \max_{x \in K} f(x)$

Extremums

Cas des fonctions d'une variable réelle.

- **Théorème de Weierstrass.** Soient K un ensemble **compact** (fermé et borné) non vide de \mathbb{R}^n et $f : K \rightarrow \mathbb{R}$ une fonction **continue** sur K , alors f admet est bornée et atteint ses bornes sur K .
- Autrement il existe toujours un point dans cet intervalle où la fonction atteint sa valeur maximale, et un autre point où elle atteint sa valeur minimale.
- C'est à dire, il existe a^* tel que : $f(a^*) = \min_{x \in K} f(x)$,
ou $f(a^*) = \max_{x \in K} f(x)$

Extremums


Cas des fonctions d'une variable réelle.

- **Théorème d'existence.** Soit $f: \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue. Si f est **coercive**, c'est-à-dire que $\lim_{\|x\| \rightarrow \infty} f(x) = +\infty$, Alors f admet au moins un minimum global sur \mathbb{R}^n .
- **Théorème d'unicité.** Soit $f: \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue. Si f est **coercive** et strictement **convexe**, alors il existe un unique minimum $a^* \in \mathbb{R}^n$ de f tel que : $\forall x \in \mathbb{R}^n, f(x) \geq f(a^*)$.
- Pour les fonctions concaves, on recherche des maxima, tandis que pour les fonctions convexes, on recherche des minima, les inégalités sont inversées.

Extremums

Cas des fonctions d'une variable réelle.

- **Exemple.** $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ définie par : $f(x, y) = x^2 + y^2 + \sin(x) + \sin(y)$
 - f est coercive
 - f est continue
 - Cette fonction est coercive et continue, donc d'après le théorème, elle admet un minimum global.
- Exercice : chercher ce minimum globale.



Extremums

Cas des fonctions de plusieurs variables : matrice Hessienne.

- On peut généraliser les résultats précédents aux fonctions de plusieurs variables afin de déterminer la nature locale des points critiques en utilisant la matrice **Hessienne**.

Extremums

Cas des fonctions de plusieurs variables.

- **Définition.** Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de n variables. La matrice **Hessienne** de f en $x = (x_1, \dots, x_n)$ est la matrice $n \times n$ des dérivées partielles d'ordre 2 de f notée aussi $\nabla^2 f(x)$:

$$\nabla^2 f(x) = Hf(x) = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}(x) \right)_{1 \leq i, j \leq n}$$

- La matrice hessienne fournit des informations sur la courbure de la fonction f .
- Cela est crucial pour déterminer si un point critique est un minimum, un maximum ou un point de selle.

Extremums

Cas des fonctions de plusieurs variables.

- Dans le cas d'une fonction de deux variables la matrice hessienne est noté $\nabla^2(f)(x)$ est une matrice contenant les dérivées partielles d'ordre 2 en x.

- $\nabla^2 f(x,y) = \mathbf{H}f(x, y) = \begin{pmatrix} \frac{\partial^2 f(x,y)}{\partial x \partial x} & \frac{\partial^2 f(x,y)}{\partial y \partial x} \\ \frac{\partial^2 f(x,y)}{\partial x \partial y} & \frac{\partial^2 f(x,y)}{\partial y \partial y} \end{pmatrix}$

- Exemple: $f(x,y)=x^2+xy$, $\nabla^2 f(x,y) = \mathbf{H}f(x, y) = \begin{pmatrix} 2 & 1 \\ 1 & 0 \end{pmatrix}$

Extremums

Cas des fonctions de plusieurs variables. hessienne de

- Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Sa hessienne est :

$$\nabla^2 f(x) = Hf(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

Extremums

Cas des fonctions de plusieurs variables :

- **Définition.** Soit $f : U \rightarrow \mathbb{R}$ une fonction de deux variables, où U est un ouvert de \mathbb{R}^n .
 - On dit que f admet un **maximum local** (resp. minimum local) en $X^* \in U$ s'il existe un voisinage ouvert $D \subset U$, centré en X^* , tel que : $\forall X \in D \ f(X) \leq f(X^*)$ (resp. $f(X) \geq f(X^*)$).
 - On dit que f admet un **extremum local** en $f(X^*)$ si elle y admet un maximum local ou un minimum local.

Extremums

Cas des fonctions de plusieurs variables.

- **Proposition (condition nécessaire du premier ordre).** Si $f : U \subset \mathbb{R}^n \rightarrow \mathbb{R}$ admet un extremum local en un point (a_0, \dots, a_1) , alors la condition nécessaire de premier ordre pour que f ait un extremum local à a est que le gradient de f au point a soit nul, c'est à dire :

$$\nabla f(a) = \left(\frac{\partial f}{\partial x_1}(a_1, \dots, a_n), \frac{\partial f}{\partial x_2}(a_1, \dots, a_n), \dots, \frac{\partial f}{\partial x_n}(a_1, \dots, a_n) \right) = (0, \dots, 0).$$

- Dans le cas de $n=2$, cela se traduit par :

$$\frac{\partial f}{\partial x}(a_0, a_1) = 0 \text{ et } \frac{\partial f}{\partial y}(a_0, a_1) = 0.$$

Extremums

Cas des fonctions de plusieurs variables: hessienne

- **Théorème (Conditions suffisantes).** Soit f une fonction de classe C^2 sur un ouvert U , et soit $x = (x_1, \dots, x_n) \in U$ un point critique de f c'est-à-dire que $\nabla f(x) = (0, \dots, 0)$.
 - Si $\nabla^2 f(x)$ est **définie positive** alors f admet un **minimum strict local** en x .
 - Si $\nabla^2 f(x)$ est **définie négative**, alors f admet un **maximum strict local** en x .
 - Si $\nabla^2 f(x)$ est **indéfinie** (c'est-à-dire qu'il existe des vecteurs v et w tels que $v^T Hf(x) v > 0$ et $w^T Hf(x) w < 0$), alors x est un **point selle** et il n'existe pas d'extremum local en ce point.

Extremums

Cas des fonctions de plusieurs variables: hessienne

- **Théorème (Conditions nécessaire).** Soit f une fonction de classe C^2 sur un ouvert U , et soit $x = (x_1, \dots, x_n) \in U$ un point critique de f c'est-à-dire que $\nabla f(x) = (0, \dots, 0)$.
 - Si x_0 est un minimum local, alors la matrice hessienne de f en x_0 est semi-définie positive : $\nabla^2 f(x_0) \geq 0$.
 - Si x_0 est un maximum local, alors la matrice hessienne de f en x_0 est semi-définie négative: $\nabla^2 f(x_0) \leq 0$.

Extremums


Cas des fonctions de plusieurs variables.

- **Théorème (Critère de Monge).** Soit $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ une fonction de classe C^2 et soit (x_0, y_0) un point critique de f .
- On pose $r = \frac{\partial^2 f(x,y)}{\partial x \partial x}$, $t = \frac{\partial^2 f(x,y)}{\partial y \partial y}$, $s = \frac{\partial^2 f(x,y)}{\partial x \partial y}$, $\nabla^2 f(x,y) = \mathbf{H}f(x, y) = \begin{pmatrix} r & s \\ s & t \end{pmatrix}$
- Alors : $\text{Det}(\nabla^2 f(x,y)) = rt - s^2$
 - Si $\text{Det}(\nabla^2 f(x,y)) > 0$ et $r > 0$, alors (x_0, y_0) est un **minimum** local de f ,
 - si $\text{Det}(\nabla^2 f(x,y)) > 0$ et $r < 0$, alors (x_0, y_0) est un **maximum** local de f
 - si $\text{Det}(\nabla^2 f(x,y)) = 0$, on ne peut pas conclure directement (il faut approfondir l'étude).


Extremums

■ Exemples:


- $f: x \rightarrow x^2$, a minimum local en 0, on a $f'(0) = 0$ et $f''(0) > 0$.
- $f: x \rightarrow -x^2$, a maximum local en 0, on a $f'(0) = 0$ et $f''(0) < 0$.
- $f: x \rightarrow x^3$, n'a ni minimum ni maximum local en 0, on a $f'(0) = 0$ et $f''(0) = 0$.



$$f(x) = x^2$$



$$f(x) = -x^2$$



$$f(x) = x^3$$

Extremums


■ Exemples:

• $f: (x,y) \rightarrow f(x,y) = xy^2 + x^4 - y^4$, Supposons que f admet un extremum, donc

$$\begin{cases} \frac{\partial f(x,y)}{\partial x} = y^2 + 4x^3 = 0 \\ \frac{\partial f(x,y)}{\partial y} = 2xy - 4y^3 = 0 \end{cases} \quad (0,0) \text{ est le seul point critique}$$

$$\nabla^2 f(x,y) = \begin{pmatrix} 12x^2 & 2y \\ 2y & 2x - 12y^2 \end{pmatrix} \quad \nabla^2 f(0,0) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$$

$\text{Det}(\nabla^2 f(0,0)) = 0$ donc $(0,0)$ est un point de selle.



Extremums


■ Exemples:

• $f : (x,y) \rightarrow f(x,y) = \mathbf{f(x,y)=x^2+xy+y^2-3x-6y}$, Supposons que f admet un extremum, donc

$$\begin{cases} \frac{\partial f(x,y)}{\partial x} = 2x+y-3 = 0 \\ \frac{\partial f(x,y)}{\partial y} = x+2y-6 = 0 \end{cases} \quad (0,3) \text{ est le seul point critique}$$

$$\nabla^2 f(x,y) = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \quad \nabla^2 f(0,3) = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

$\text{Det}(\nabla^2 f(0, 3))=3$, La Hessienne est définie positive (courbure convexe).
donc $(0,3)$ est un point minimum local.



Extremums

Important.

- Un extremum est un point critique mais pas la réciproque.
- Un point critique qui n'est ni un maximum local ni un minimum local est nommé point-selle (ou point-col).
- Les points de selle sont importants en optimisation car ils peuvent **piéger** les algorithmes de recherche d'extrema.
- En effet, un algorithme peut converger vers un point de selle au lieu d'un minimum global.

