

Algorithmes d'optimisation

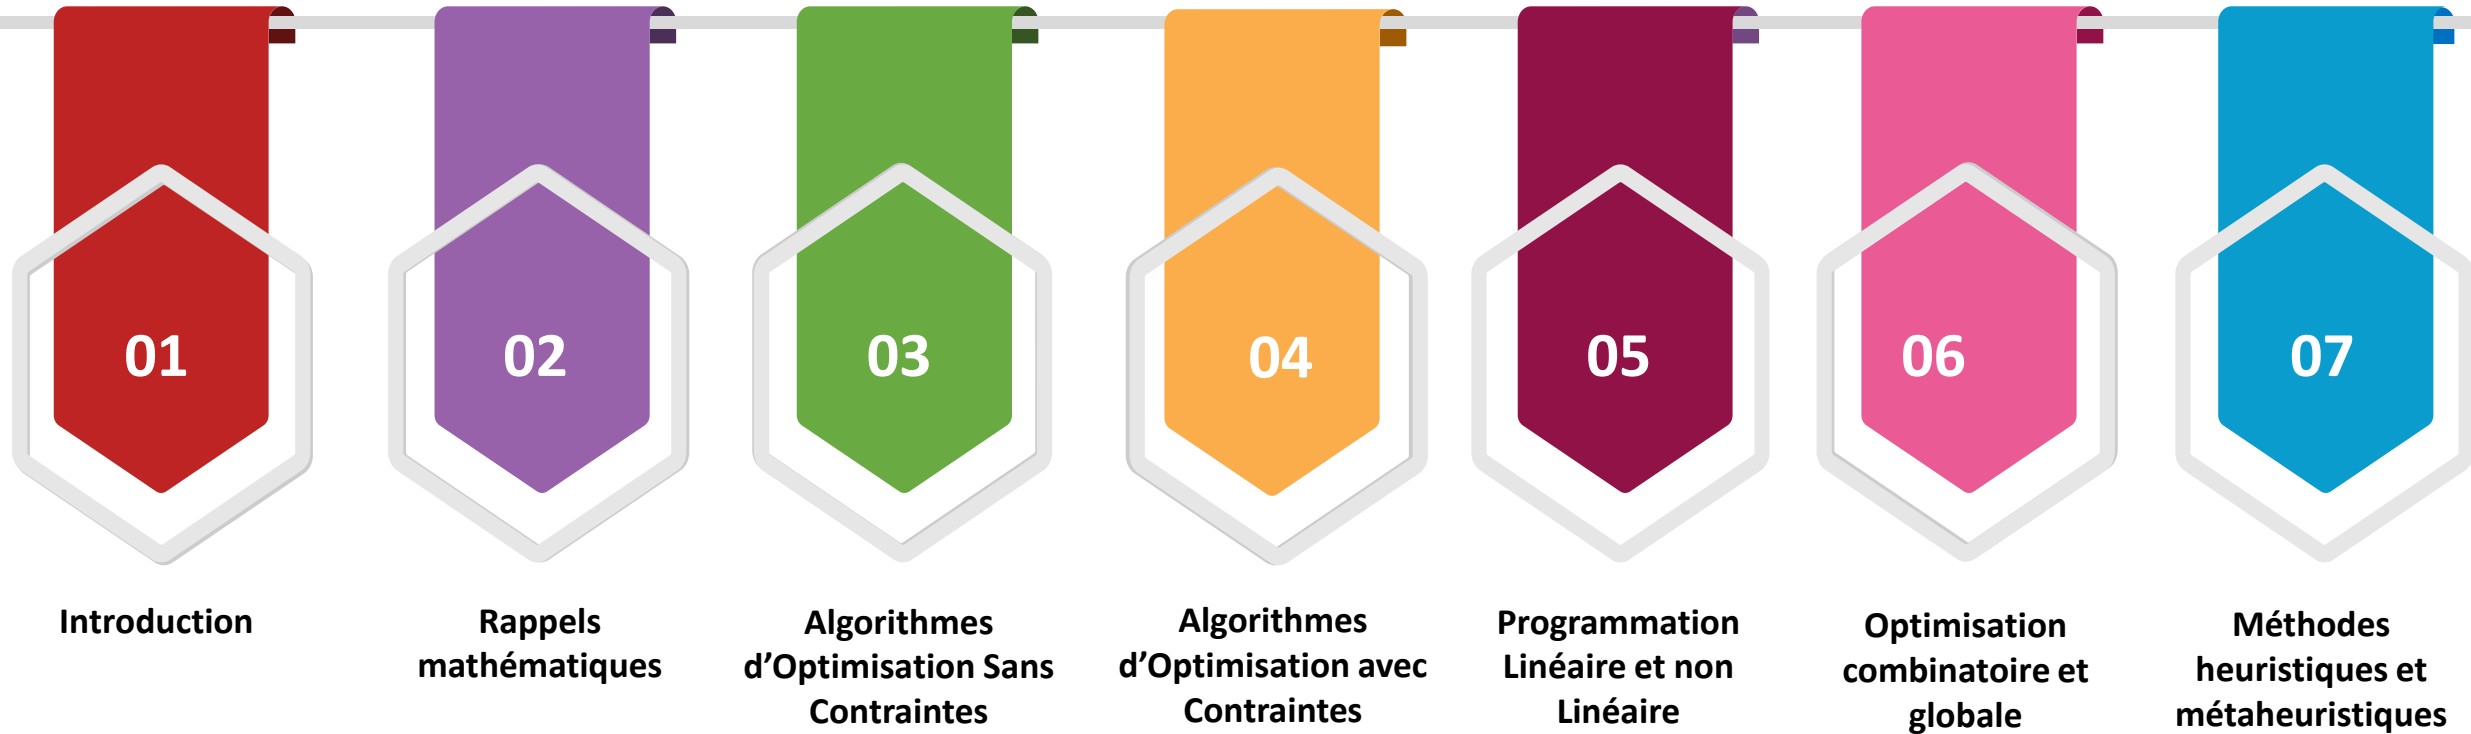
Pr. Faouzia Benabbou (faouzia.benabbou@univh2c.ma)

Département de mathématiques et Informatique

Master Data Science & Big Data

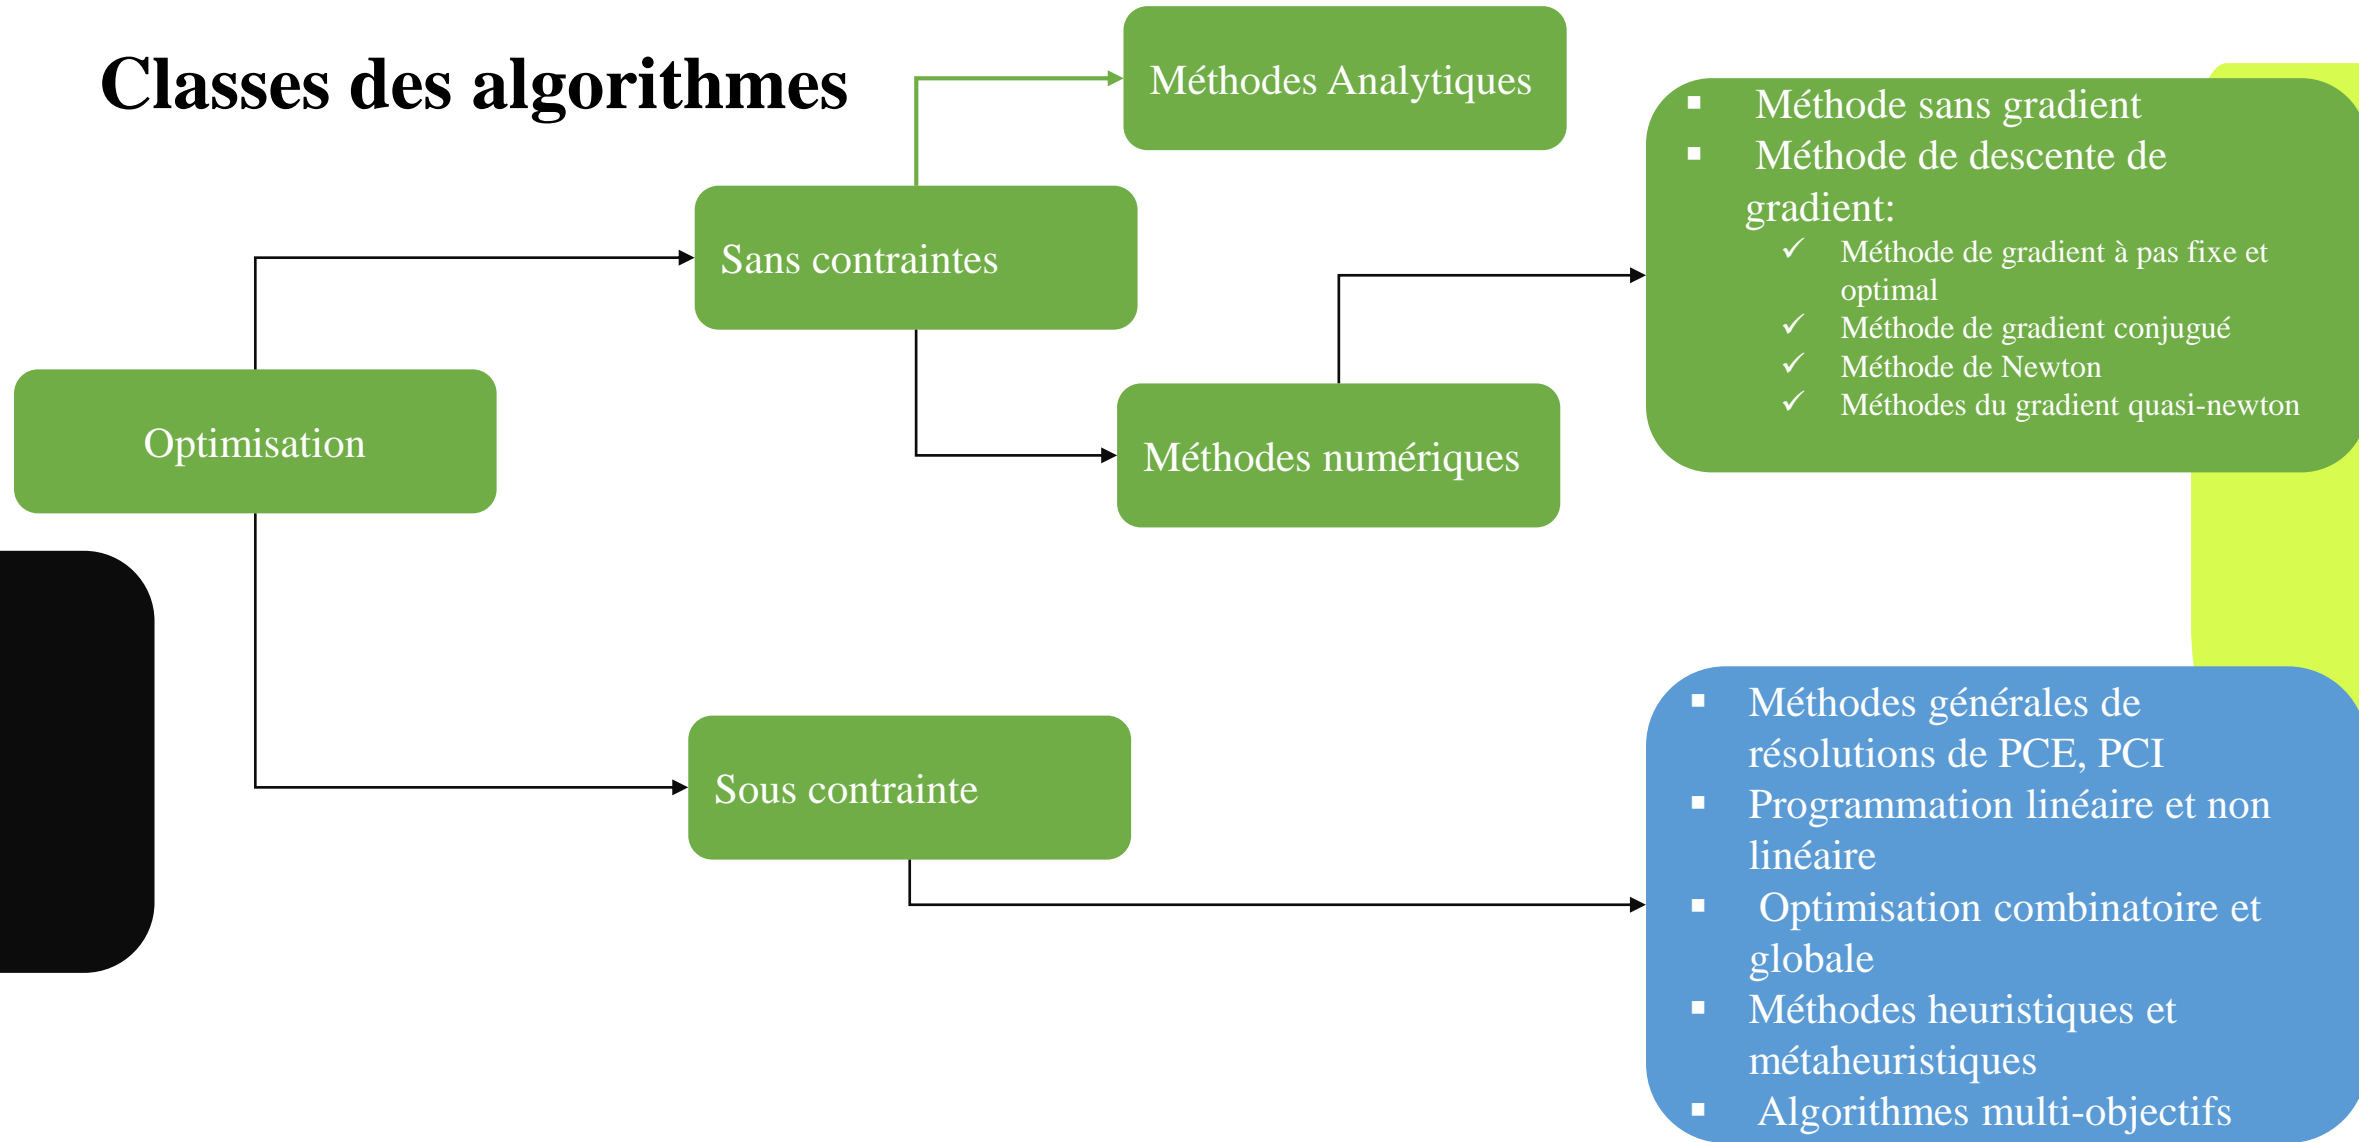
2024-2025

Plan du Module: Algorithmes d'optimisation



Les algorithmes d'optimisation

Classes des algorithmes



Méthodes d'optimisation Sous contraintes

■ Méthode d'Optimisation quadratique Séquentielle (OQS)

- La méthode **OQS** plus connue sous le nom de SQP(Sequential Quadratic Programming) est une technique pour résoudre les **problèmes d'optimisation non linéaire sous contraintes**.
- Elle consiste à remplacer le problème initial par une suite de **problèmes quadratiques** sous contraintes linéaires plus faciles à résoudre.
- C'est une méthode qui combine la méthode de **Newton** et la **programmation quadratique** pour résoudre efficacement des problèmes **non linéaires avec contraintes**.

Méthodes d'optimisation Sous contraintes

■ La méthode Sequential Quadratic Programming

Considérons un problème d'optimisation (différentiable) avec contraintes d'égalité :

$$(P) \begin{cases} \min_{x \in \mathbb{R}^n} f(x), & f \text{ une fonction objective de .} \\ h(x) = 0 . \end{cases}$$

où $f : \mathbb{R}^n \rightarrow \mathbb{R}$ et $h : \mathbb{R}^n \rightarrow \mathbb{R}^p$, f et h au moins différentiable.

On transforme le problème (P) en (P_λ) avec la méthode de Lagrange

$$P_\lambda \begin{cases} L(x, \lambda) = f(x) + \lambda^T h(x) \\ \text{s. c. } h(x) = 0 \end{cases}$$

Méthodes d'optimisation Sous contraintes

- La méthode Sequential Quadratic Programming

$$\text{soit } F(x, \lambda) = \begin{cases} F1(x, \lambda) = \nabla L(x, \lambda) \\ F2(x, \lambda) = h(x) \end{cases} \quad (1)$$

- On cherche à résoudre $F(x, \lambda) = 0$

$$(1) \begin{cases} F1(x, \lambda) = 0. \\ F2(x, \lambda) = 0. \end{cases} \Leftrightarrow \begin{cases} \nabla f(x) + \nabla h(x)^T \lambda = 0. \\ h(x) = 0. \end{cases}$$

- Pour résoudre (1) on peut utiliser la méthode de Newton-Raphson où la formule itérative suivante:

$$x_{k+1} = x_k - \frac{f(x_k)}{\nabla f(x_k)} \text{ est utilisée au lieu de } x_{k+1} = x_k - \frac{f(x_k)}{\nabla^2 f(x_k)}.$$

Méthodes d'optimisation Sous contraintes

- La méthode Sequential Quadratic Programming

Newton-Raphson appliquée à $F(x, \lambda)$:

$$\begin{pmatrix} x_{k+1} - x_k \\ \lambda_{k+1} - \lambda_k \end{pmatrix} = - \frac{F(x_k, \lambda_k)}{\nabla F(x_k, \lambda_k)}$$

$$\text{Donc : } \nabla F(x_k, \lambda_k) \begin{pmatrix} x_{k+1} - x_k \\ \lambda_{k+1} - \lambda_k \end{pmatrix} = - F(x_k, \lambda_k) \quad (2)$$

Calculons la matrice jacobienne de F.

$$\nabla F(x, \lambda) = \begin{pmatrix} \frac{\nabla F_1(x, \lambda)}{\nabla x} & \frac{\nabla F_1(x, \lambda)}{\nabla \lambda} \\ \frac{\nabla F_2(x, \lambda)}{\nabla x} & \frac{\nabla F_2(x, \lambda)}{\nabla \lambda} \end{pmatrix},$$

Méthodes d'optimisation Sous contraintes

- La méthode Sequential Quadratic Programming
- Newton-Raphson appliquée à $F(x, \lambda)$:

$$\nabla F(x, \lambda) = \begin{pmatrix} \frac{\nabla F_1(x, \lambda)}{\nabla x} & \frac{\nabla F_1(x, \lambda)}{\nabla \lambda} \\ \frac{\nabla F_2(x, \lambda)}{\nabla x} & \frac{\nabla F_1(x, \lambda)}{\nabla \lambda} \end{pmatrix} = \nabla F(x, \lambda) = \begin{pmatrix} \frac{\nabla^2 L(x, \lambda)}{\nabla x^2} & \nabla h(x)^T \\ \nabla h(x) & 0 \end{pmatrix}$$

on pose $H_L(x, \lambda) = \frac{\nabla^2 L(x, \lambda)}{\nabla x^2}$, $\nabla F(x, \lambda) = \begin{pmatrix} H_L(x, \lambda) & \nabla h(x)^T \\ \nabla h(x) & 0 \end{pmatrix}$

$$(2) \quad \nabla F(x_k, \lambda_k) \begin{pmatrix} x_{k+1} - x_k \\ \lambda_{k+1} - \lambda_k \end{pmatrix} = -F(x_k, \lambda_k)$$

on obtient :

$$\begin{cases} H_L(x_k, \lambda_k)(x_{k+1} - x_k) + \nabla h(x_k)^T(\lambda_{k+1} - \lambda_k) = -\nabla f(x_k) - \nabla h(x_k)^T \lambda_k \\ \nabla h(x_k)^T(x_{k+1} - x_k) = -h(x_k) \end{cases}$$

Méthodes d'optimisation Sous contraintes

■ La méthode Sequential Quadratic Programming

Après simplification on remplace $d_k = x_{k+1} - x_k$, on obtient le système (3) suivant :

$$(3) \begin{cases} H_L(x_k, \lambda_k) \mathbf{d}_k + \nabla f(x_k) + \nabla h(x_k)^T (\lambda_{k+1}) = 0 \\ \nabla h(x_k)^T \mathbf{d}_k + h(x_k) = 0. \end{cases}$$

Ici on cherche la variation \mathbf{d}_k , et le multiplicateur λ_{k+1} qui permettent de résoudre le système (2).

On remarque que (3) formule les **conditions d'optimalité** du **problème quadratique** suivant :

$$(4) \begin{cases} \min_{d \in \mathbb{R}^n} \frac{1}{2} d^T H_L(x_k, \lambda_k) d + \nabla f(x_k)^T d, & f \text{ fonction objective} \\ \nabla h(x_k)^T d + h(x_k) = 0 \end{cases}$$

Méthodes d'optimisation Sous contraintes

- La méthode Sequential Quadratic Programming

$$(3) \begin{cases} H_L(x_k, \lambda_k) \mathbf{d}_k + \nabla f(x_k) + \nabla h(x_k)^T (\lambda_{k+1}) = 0 \\ \nabla h(x_k)^T \mathbf{d}_k + h(x_k) = 0. \end{cases}$$

$$(QP) \begin{cases} \min_{d \in \mathbb{R}^n} \frac{1}{2} d^T H_L(x_k, \lambda_k) d + \nabla f(x_k)^T d, f \text{ fonction objective} \\ \nabla h(x_k)^T d + h(x_k) = 0 \end{cases}$$

- Preuve** : formulons le lagrangien du problème (QP):

$$L(d, \lambda) = \frac{1}{2} d^T H_L(x_k, \lambda_k) d + \nabla f(x_k)^T d + \lambda (\nabla h(x_k)^T d + h(x_k))$$

la condition d'optimalité du premier ordre est : $\nabla L(d, \lambda) = 0$.

$$\begin{aligned} \nabla L(d, \lambda) &= \nabla_d \left(\frac{1}{2} d^T H_L(x_k, \lambda_k) d + \nabla f(x_k)^T d + \lambda (\nabla h(x_k)^T d + h(x_k)) \right). \\ &= H_L(x_k, \lambda_k) d + \nabla f(x_k) + \nabla h(x_k)^T \lambda. \end{aligned}$$

λ est exactement le λ_{k+1} qu'on cherche dans (3) et d c'est la direction qu'on cherche \mathbf{d}_k .
Donc pour trouver (d, λ) il suffit de résoudre le système linéaire (2) et trouver (d_k, λ_{k+1}) .

Méthodes d'optimisation Sous contraintes

▪ La méthode Sequential Quadratic Programming

Algorithme 10. Méthode SQP sous contrainte d'égalité

1. Initialisation : $x_0, \varepsilon, k = 0, \max_iter, f: \mathbb{R}^n \rightarrow \mathbb{R}, h: \mathbb{R}^n \rightarrow \mathbb{R}^p, \lambda_k$

2. Répéter

a) Résoudre le problème quadratique pour obtenir la solution primale d_k et le multiplicateur λ_{k+1} :

$$QP \begin{cases} \min_{d \in \mathbb{R}^n} \frac{1}{2} d^T H_L(x_k, \lambda_k) d + \nabla f(x_k)^T d . \\ \text{s. c. } \nabla h(x)^T d + h(x) = 0 . \end{cases}$$

a) Mettre à jour la solution : $x_{k+1} = x_k + d_k$

b) Mettre à jour λ_{k+1} avec la nouvelle valeur trouvée

c) $k++$

3. jusqu'à ce que $\|\nabla L(x_n, \lambda_k)\| < \varepsilon$ ou $k > \max_iter$

4. retourner x_k

Méthodes d'optimisation Sous contraintes

▪ La méthode Sequential Quadratic Programming

Exemples. Trouver le minimum de la fonction $f(x,y) = x_1^2 + 2(x_2 - 2)^2$ sous contrainte $h(x,y) = x_1^2 + x_2^2 - 1$

a) Résoudre le problème quadratique QP qui revient à résoudre le problème linéaire :

$$\nabla F(x_k, \lambda_k) \begin{pmatrix} x_{k+1} - x_k \\ \lambda_{k+1} - \lambda_k \end{pmatrix} = -F(x_k, \lambda_k) \quad (2)$$

Lagrangien : $L(x_1, x_2, \lambda) = x_1^2 + 2(x_2 - 2)^2 + \lambda(x_1^2 + x_2^2 - 1)$

Le gradient de L : $\nabla L(x_1, x_2, \lambda) = \begin{pmatrix} 2x_1 + 2\lambda x_1 \\ 4(x_2 - 2) + 2\lambda x_2 \end{pmatrix}$, $\nabla h(x_1, x_2) = \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix}$

La hessienne de L : $H_L(x_1, x_2, \lambda) = \begin{pmatrix} 2 + 2\lambda & 0 \\ 0 & 4 + 2\lambda \end{pmatrix}$,

$\nabla f(x_1, x_2) = (2x_1 \quad 4x_2 - 8)$

Méthodes d'optimisation Sous contraintes

▪ La méthode Sequential Quadratic Programming

Exemples. Trouver le minimum de la fonction $f(x,y) = x_1^2 + 2(x_2 - 2)^2$ sous contrainte $h(x,y) = x^2 + y^2 - 1$

Itération 0 :

$$k=0 ; x_0 = \left(-\frac{1}{2}, \frac{1}{2}\right), \lambda_0 = 1.$$

$$H_L(x_0, 1) = \begin{pmatrix} 4 & 0 \\ 0 & 6 \end{pmatrix}, \nabla f(x_0) = (-1, -6)^t, \nabla h(x_0)^T = (-1, 1)^t$$

$$h(x_0) = -\frac{1}{2}$$

Méthodes d'optimisation Sous contraintes

▪ La méthode Sequential Quadratic Programming

Exemples. Trouver le minimum de la fonction $f(x,y) = x_1^2 + 2(x_2 - 2)^2$ sous contrainte $h(x,y) = x^2 + y^2 - 1$

Itération 0 :

la résolution du sous-problème quadratique est équivalente à la résolution du système linéaire (2) pour k_0 :

$$\text{on a } \nabla F(x_0, \lambda_0) = \begin{pmatrix} \frac{\nabla^2 L(x_0, \lambda_0)}{\nabla x^2} & \nabla h(x_0)^T \\ \nabla h(x_0) & 0 \end{pmatrix} = \begin{pmatrix} 4 & 0 & 1 \\ 0 & 6 & -1 \\ -1 & 1 & 0 \end{pmatrix}$$
$$\begin{pmatrix} 4 & 0 & 1 \\ 0 & 6 & -1 \\ -1 & 1 & 0 \end{pmatrix} \begin{pmatrix} d_1 \\ d_2 \\ \lambda_1 \end{pmatrix} = - \begin{pmatrix} \nabla f(x_0) \\ h(x_0) \end{pmatrix} = - \begin{pmatrix} -1 \\ -6 \\ -\frac{1}{2} \end{pmatrix}$$

on obtient le système suivant
$$\begin{cases} 4d_1 + \lambda_1 = 1 \\ 6d_2 - \lambda_1 = 6 \\ -d_1 + d_2 = \frac{1}{2} \end{cases},$$

Méthodes d'optimisation Sous contraintes

- La méthode Sequential Quadratic Programming

Exemples. Trouver le minimum de la fonction $f(x,y) = x_1^2 + 2(x_2 - 2)^2$ sous contrainte $h(x,y) = x^2 + y^2 - 1$

Itération 0 : (3)
$$\begin{cases} 4d_1 - 1 + \lambda_1 = 0 \\ 6d_2 - 6 - \lambda_1 = 0 \\ -d_1 + d_2 = \frac{1}{2} \end{cases}, \begin{cases} d_1 = 2/5 \\ d_2 = 9/10 \\ \lambda_1 = -\frac{3}{5} \end{cases}$$

Mise à jour : $x_1 = x_0 + d = \begin{pmatrix} -\frac{1}{10} \\ \frac{14}{10} \end{pmatrix}, \lambda_1 = -\frac{3}{5}$

...

Méthodes d'optimisation Sous contraintes

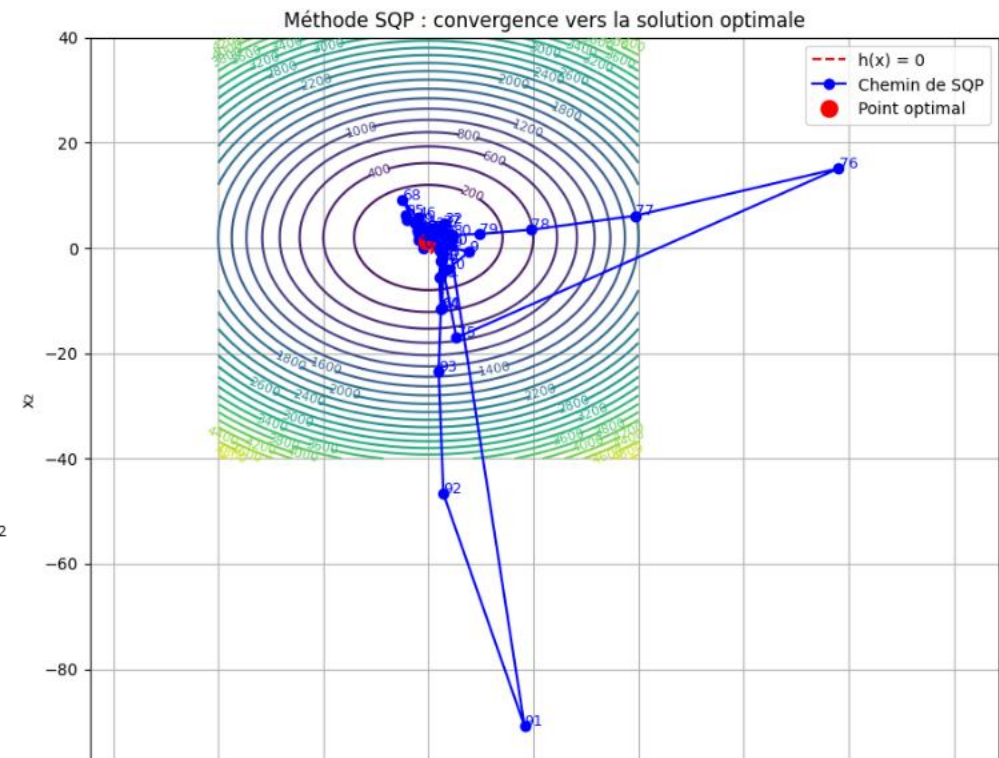
▪ La méthode Sequential Quadratic Programming

Exemples. Trouver le minimum de la fonction $f(x,y) = x_1^2 + 2(x_2 - 2)^2$ sous contrainte $h(x,v) = x^2 + v^2 - 1$. $\text{tol} = 1e-6$.

```
max_ : 1.0000000000000000e+000 0.0000000000000000e+000
=== ITERATION 99 ===
x_k = [0.25917234 1.75709675]
λ_k = -0.19606056685356382
∇f(x_k) = [ 0.51834468 -0.97161299]
∇h(x_k) = [0.51834468 3.51419351]
H_f(x_k) =
[[2.  0.]
 [0.  4.]]
H_h(x_k) =
[[2.  0.]
 [0.  2.]]
H (modifiée) H_f + λ * H_h =
[[1.60787887  0.          ]
 [ 0.         3.60787887]]
Système résolu linéaire : A =
[[ 1.60787887  0.         -0.51834468]
 [ 0.         3.60787887 -3.51419351]
 [ 0.51834468 3.51419351  0.          ]]
Système résolu linéaire : b = [-0.51834468  0.97161299 -2.1545593 ]
Solution: d = [-0.5858302132819211, -0.5266919204845274], λ = -0.817215566925802
Norme de d = 0.7877825955792759, tol = 1e-6

Solution optimale trouvée : x = [-0.32665787  1.23040483], λ = -0.817215566925802
```

Solution optimale trouvée : x = [-0.32665787 1.23040483], λ = -0.817215566925802



Méthodes d'optimisation Sous contraintes

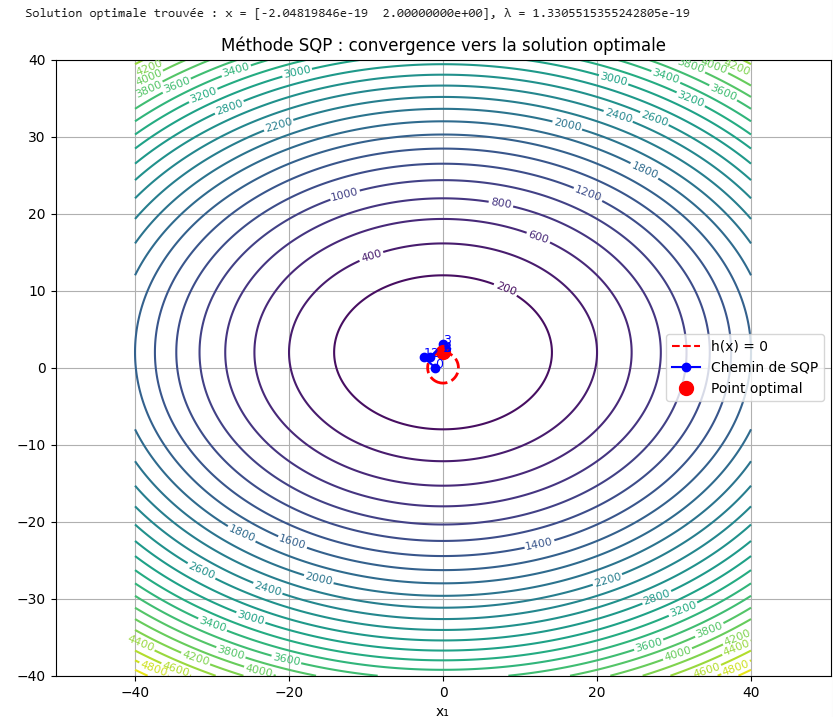
■ La méthode Sequential Quadratic Programming

Exemples. Trouver le minimum de la fonction $f(x,y) = x_1^2 + 2(x_2 - 2)^2$ sous contrainte $h(x,y) = x^2 + y^2 - 4$

```

=== ITERATION 7 ===
x_k = [-5.43958144e-10  2.00000000e+00]
λ_k = 3.7653604352534426e-10
∇f(x_k) = [-1.08791629e-09  4.52015314e-10]
∇h(x_k) = [-1.08791629e-09  4.00000000e+00]
H_f(x_k) =
[[2.  0.]
 [0.  4.]]
H_h(x_k) =
[[2.  0.]
 [0.  2.]]
H (modifiée) H_f + λ * H_h =
[[2.  0.]
 [0.  4.]]
Système résolu linéaire : A =
[[ 2.00000000e+00  0.00000000e+00  1.08791629e-09]
 [ 0.00000000e+00  4.00000000e+00 -4.00000000e+00]
 [-1.08791629e-09  4.00000000e+00  0.00000000e+00]]
Système résolu linéaire : b = [ 1.08791629e-09 -4.52015314e-10 -4.52015314e-10]
Solution: d = [5.439581435449709e-10, -1.1300382836253647e-10], λ = 1.3305515355242805e-19
Norme de d = 5.555720719703977e-10, tol = 1e-6
    
```

Convergence atteinte !



Méthodes d'optimisation Sous contraintes

■ La méthode Sequential Quadratic Programming

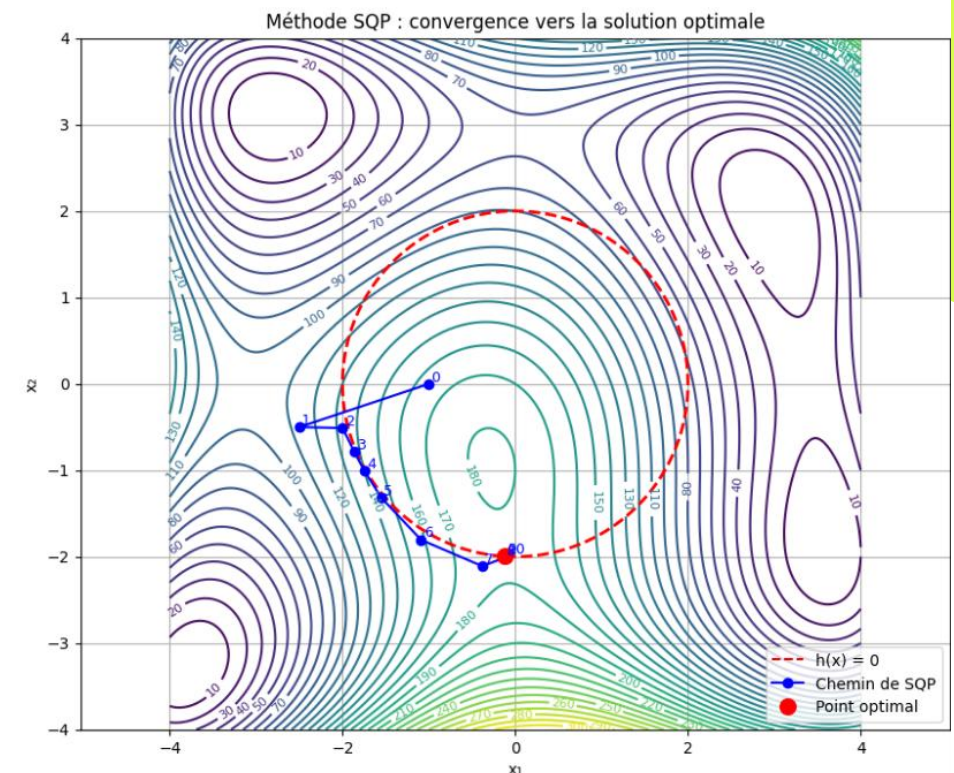
Exemples. Trouver le minimum de la fonction $f(x,y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2$ sous contrainte $h(x,y) = x^2 + y^2 - 4$

$x_0 = [-1, 0]$, $\lambda_0 = 1$, $\text{tol} = 1\text{e-}6$, $\text{max_iter} = 10$

```

=== ITERATION 9 ===
x_k = [-0.11938612 -1.99653736]
λ_k = 0.2291509558149751
∇f(x_k) = [-0.06683101 -0.94216807]
∇h(x_k) = [-0.23877225 -3.99307473]
H_f(x_k) =
[[-49.8151129  -8.46369394]
 [ -8.46369394  21.35639282]]
H_h(x_k) =
[[2.  0.]
 [0.  2.]]
H (modifiée) H_f + λ * H_h =
[[-49.35681099  -8.46369394]
 [ -8.46369394  21.81469473]]
Système résolu linéaire : A =
[[-49.35681099  -8.46369394  0.23877225]
 [ -8.46369394  21.81469473  3.99307473]
 [ -0.23877225  -3.99307473  0.        ]]
Système résolu linéaire : b = [ 6.68310068e-02  9.42168067e-01 -4.14488520e-04]
Solution: d = [-0.00023839506442932662, 0.0001180570556405311], λ = 0.234800260486828
Norme de d = 0.00026602570389113573, tol = 1e-6

Solution optimale trouvée : x = [-0.11962452 -1.99641931], λ = 0.234800260486828
    
```



Méthodes d'optimisation Sous contraintes

■ La méthode Sequential Quadratic Programming

• Avantages

- ✓ La méthode SQP est très efficace pour traiter les problèmes d'optimisation avec des contraintes non linéaires.
- ✓ Elle est adaptée pour résoudre des problèmes d'optimisation à grande échelle avec de nombreuses variables et contraintes.
- ✓ la méthode SQP peut approcher la solution par des points réalisables et non réalisables, ce qui est avantageux lorsqu'il est difficile de trouver un point de départ réalisable.
- ✓ Convergence rapide (quadratique) proche de l'optimum

• Limites

- ✓ Chaque itération de la méthode SQP implique la résolution d'un sous-problème de programmation quadratique (PQ), ce qui peut être coûteux en termes de calcul, surtout pour les problèmes à grande échelle.
- ✓ Les sous-problèmes de programmation quadratique générés au sein de l'algorithme SQP peuvent devenir non réalisables ce qui aboutit à l'échec de la méthode.