

Algorithmes d'optimisation

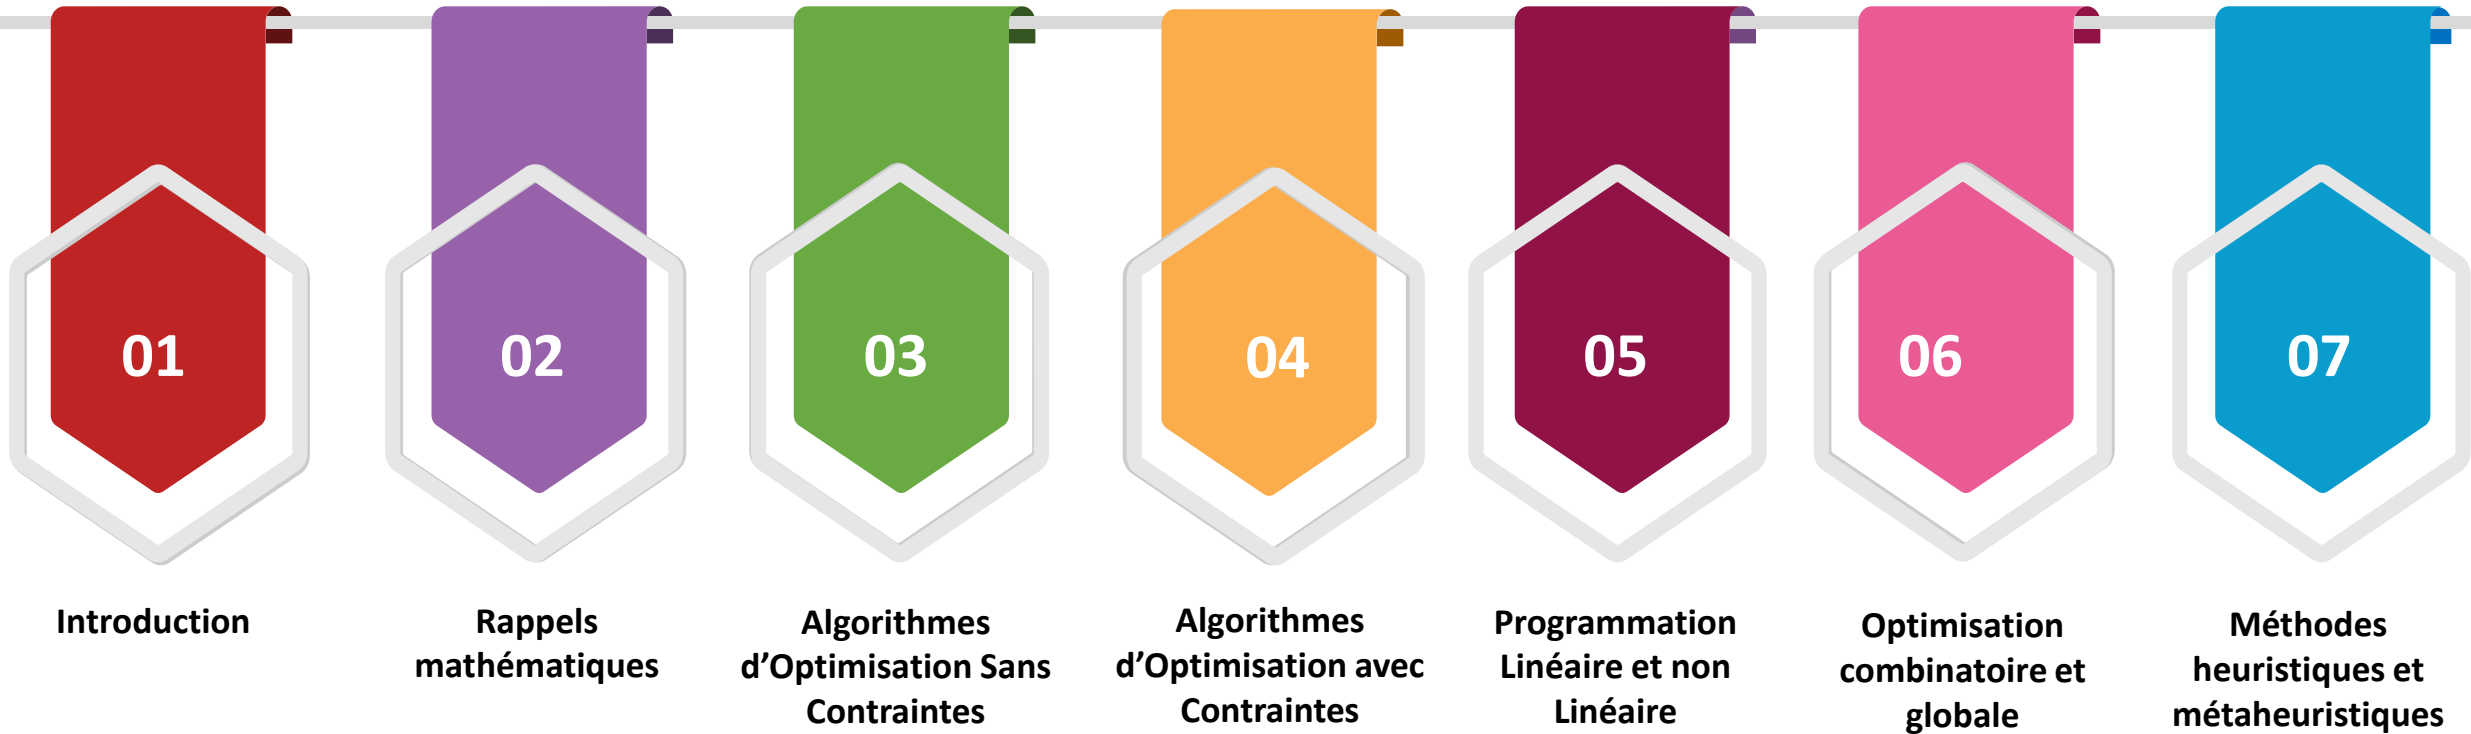
Pr. Faouzia Benabbou (faouzia.benabbou@univh2c.ma)

Département de mathématiques et Informatique

Master Data Science & Big Data

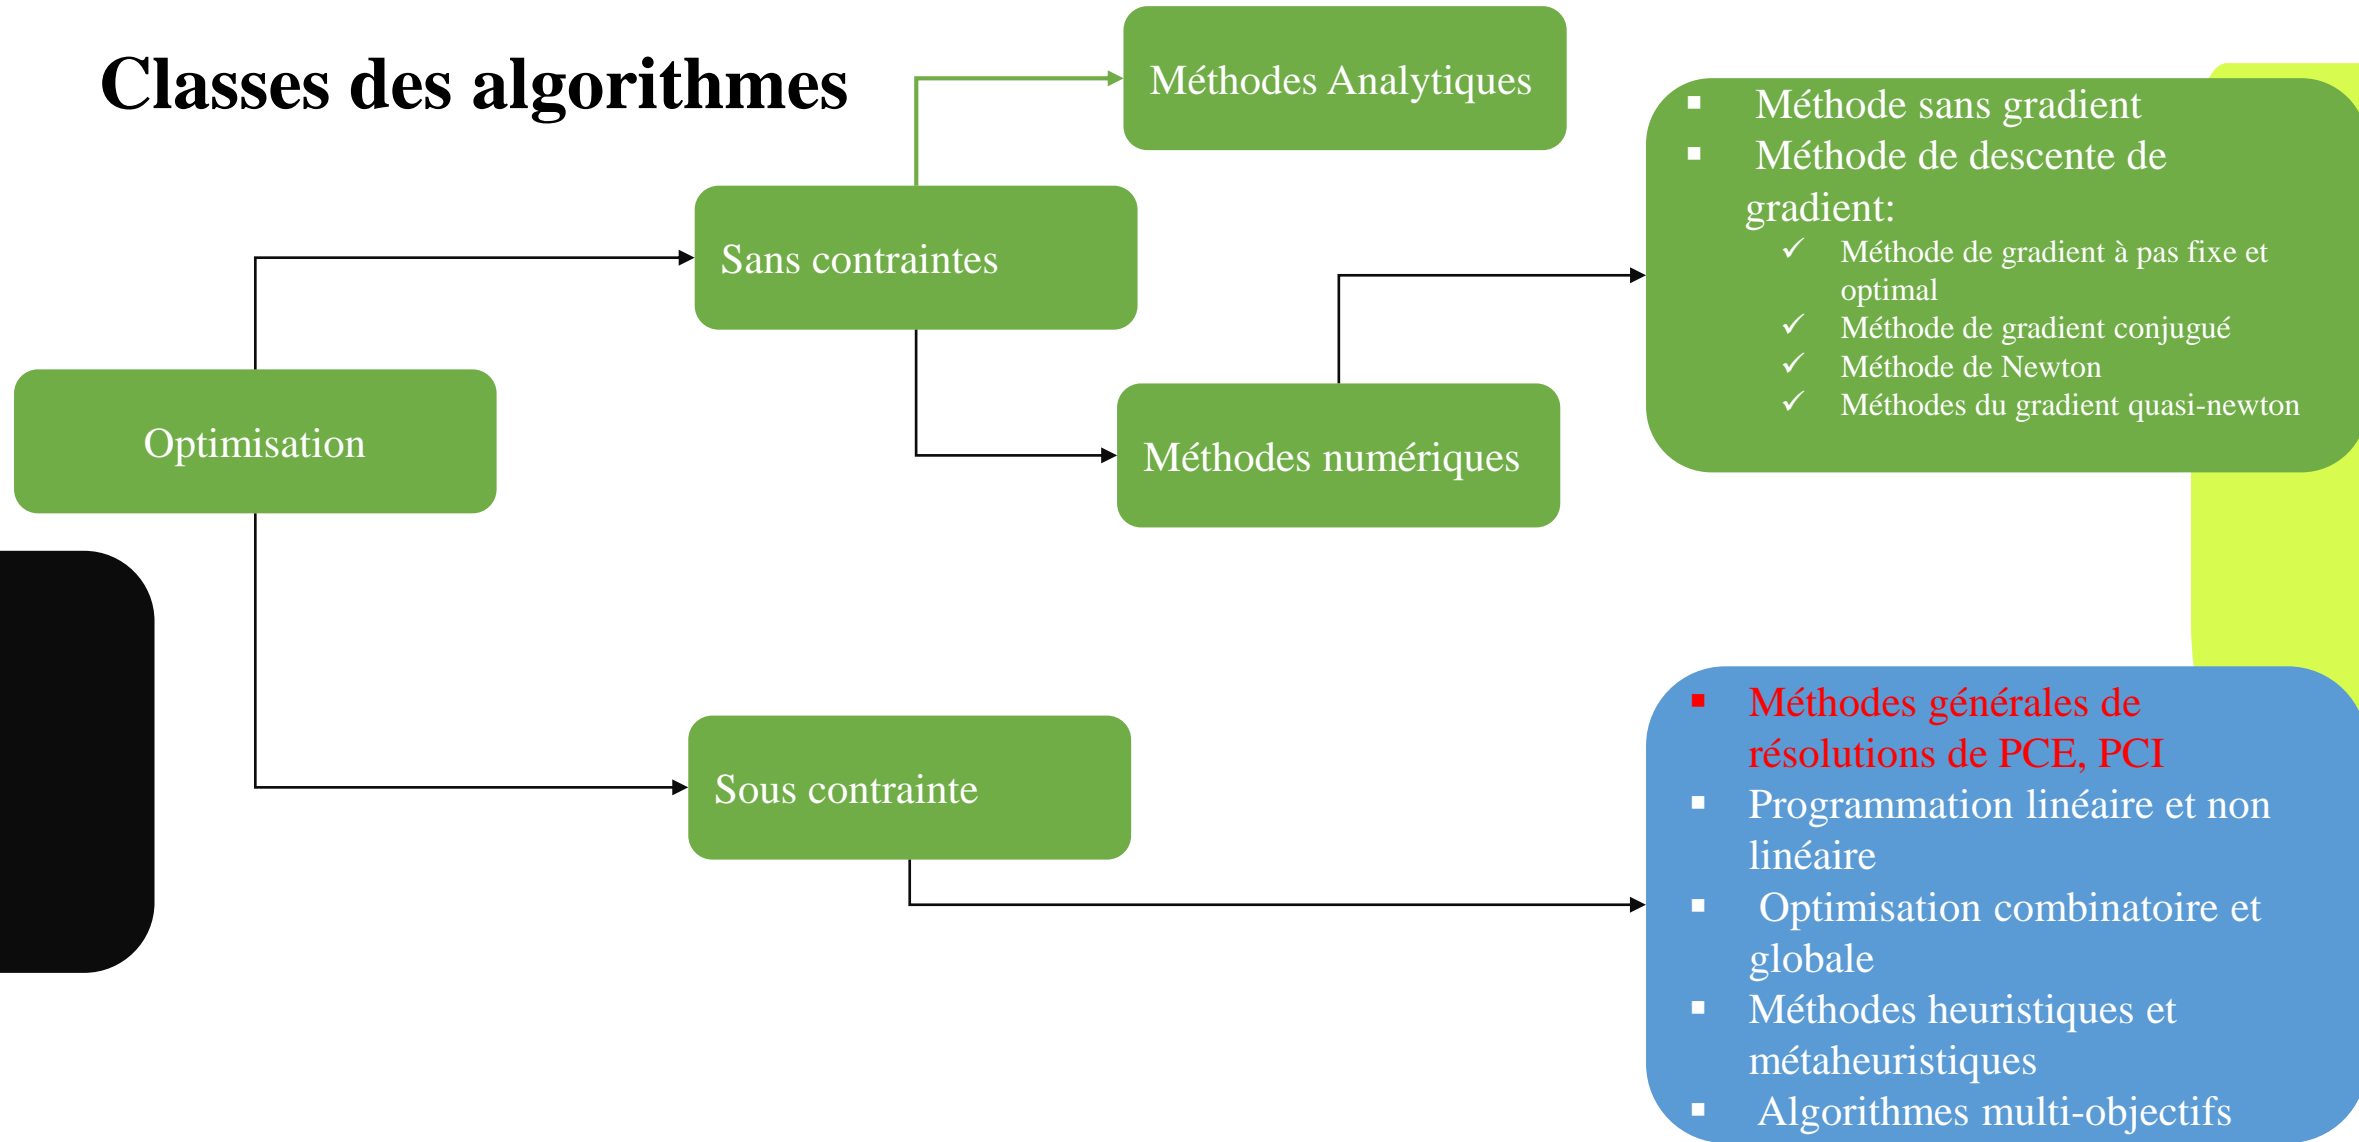
2024-2025

Plan du Module: Algorithmes d'optimisation



Les algorithmes d'optimisation

Classes des algorithmes



PO sous Contraintes d'inégalité ou mixte

- **Méthode Lagrangien augmenté (Augmented Lagrangian Method — ALM)**
 - La Méthode des Multiplicateurs de Lagrange Augmentés (ALM) est une technique d'optimisation conçue pour résoudre des **problèmes non linéaires** où l'on cherche à minimiser une fonction sous des contraintes **d'égalité et/ou d'inégalité**.
 - Son principal atout réside dans sa capacité à combiner les avantages de la méthode des **multiplicateurs de Lagrange** classique avec ceux des méthodes de **pénalisation**, tout en atténuant leurs inconvénients respectifs.
 - Comme les autres méthodes, l'ALM transforme le problème d'optimisation contraint en **une série de sous-problèmes d'optimisation** non contrainte résolubles par les méthodes classiques comme la méthode quasi-Newton BFGS.

PO sous Contraintes d'inégalité ou mixte

▪ Méthode Lagrangien augmenté

Soit le problème (P)
$$\begin{cases} \min_{x \in \mathbb{R}^n} f(x), f \text{ une fonction objective.} \\ g(x) \leq 0 \\ h(x) = 0 \end{cases}$$

- où $h : \mathbb{R}^n \rightarrow \mathbb{R}^p$ est de classe \mathbf{C}^1 , la fonction de contrainte d'égalité.
- $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$, est de classe \mathbf{C}^1 , la fonction de contrainte d'inégalité.
- $x \in \mathbb{R}^n$ est le vecteur des variables de décision.

Définition. La fonction Lagrangienne Augmentée pour un problème général avec égalités et inégalités se définit comme suit :

- $\lambda \in \mathbb{R}^p$: multiplicateurs pour égalités
- $\mu \in \mathbb{R}^m, \mu \geq 0$: multiplicateurs pour inégalités
- $\rho > 0$: paramètre de pénalisation

PO sous Contraintes d'inégalité ou mixte

- Méthode Lagrangien augmenté : Version simplifiée

$$L\rho(\mathbf{x}, \lambda, \mu) =$$

$$f(\mathbf{x}) + \lambda^T \mathbf{h}(\mathbf{x}) + \mu^T \mathbf{g}(\mathbf{x}) + \frac{\rho}{2} \left[\sum_{i=1}^p (\mathbf{h}_i(\mathbf{x}))^2 + \sum_{j=1}^m \max(\mathbf{0}, g_j(\mathbf{x}))^2 \right]$$

En d'autres termes :

$$L(\mathbf{x}, \lambda, \mu, \rho) =$$

$$\underbrace{f(\mathbf{x}) + \lambda^T \mathbf{h}(\mathbf{x}) + \frac{\rho}{2} \sum_{i=1}^p \mathbf{h}_i(\mathbf{x})^2}_{\text{}} + \underbrace{\mu^T \mathbf{g}(\mathbf{x}) + \frac{\rho}{2} \sum_{j=1}^m \max(\mathbf{0}, g_j(\mathbf{x}))^2}_{\text{}}$$

PO sous Contraintes d'inégalité ou mixte

- Méthode Lagrangien augmenté : version plus stable

$$L_{\rho}(x, \lambda, \mu) =$$

$$L(x, \lambda, \mu, \rho) = f(x) + \lambda^T h(x) + \frac{\rho}{2} \sum_{i=1}^p (h_i(x))^2 + \frac{\rho}{2} \sum_{j=1}^m \left(\max(0, g_j(x) + \frac{\mu_j}{\rho})^2 - \left(\frac{\mu_j}{\rho} \right)^2 \right)$$

Le terme $\max(0, g_j(x) + \frac{\mu_j}{\rho})$ agit comme une "**contrainte relaxée**".

- Si $g_j(x) + \frac{\mu_j}{\rho} \leq 0$, La pénalisation est nulle (contrainte inactive)
- Si $g_j(x) + \frac{\mu_j}{\rho} > 0$, La pénalisation devient quadratique en $g_j(x)$.

$$\frac{\rho}{2} \left(\max(0, g_j(x) + \frac{\mu_j}{\rho})^2 - \left(\frac{\mu_j}{\rho} \right)^2 \right) = \begin{cases} \mu_j g_j(x) + \frac{\rho}{2} g_j(x)^2 & \text{si } g_j(x) + \frac{\mu_j}{\rho} \geq 0 \\ -\frac{\mu_j^2}{2\rho} & \text{sinon} \end{cases}$$

- est un **correcteur** qui empêche les multiplicateurs μ_j de diverger.
- **Pour les problèmes complexes** cette version est plus stable et converge plus rapidement.

PO sous Contraintes d'inégalité ou mixte

■ Méthode Lagrangien augmenté

Algorithme 13. Pénalisation classique (interne)

1. Initialisation : $x_0, \varepsilon (1e-6), f : \mathbb{R}^n \rightarrow \mathbb{R}, \lambda_0, \mu_0$
paramètre de pénalité $\rho_0 > 0, \beta > 1, k=0, \text{max_iter} = 100$.

2. Répéter :

a) Résoudre le problème sans contrainte (algorithme de descente, Newton):

$$\min_{\mathbf{x}} [L(\mathbf{x}, \lambda_k, \mu_k, \rho_k)]$$

b) Mise à jour: x_{k+1} est la solution approchée

c) Mise à jour des multiplicateurs de Lagrange :

pour chaque contrainte d'égalités h_i : $\lambda_i^{k+1} = \lambda_i^k + \rho_k \cdot h_i(x_{k+1})$

pour chaque contrainte d'inégalité g_j : $\mu_j^{k+1} = \max(0, \mu_j^k + \rho_k \cdot g_j(x_{k+1}))$

d) diminuer la pénalité : $\rho_{k+1} = \beta \rho_k$,

e) violation 1 = $\max(\max_i |h_i(x_{k+1})|, \text{violation 2})$, $\text{violation 2} = \max_j (\max(0, g_j(x_{k+1})))$

3. Jusqu'à ($\text{violation1} < \varepsilon$ et $\text{violation2} < \varepsilon$) ou max_iter atteint

PO sous Contraintes d'inégalité ou mixte

■ Méthode Lagrangien augmenté

- les critères d'arrêt signifient :

- ✓ **Satisfaction des Contraintes d'Égalité** $\max_i |h_i(x_{k+1})| < \epsilon$:

- Le problème original impose que les contraintes d'égalité $h_i(x)=0$ soient satisfaites., ce critère vérifie si la valeur absolue de la fonction de contrainte d'égalité h évaluée à la solution courante x_{k+1} est suffisamment proche de zéro. Si cette condition est satisfaite pour toutes les contraintes d'égalité, cela signifie que la solution courante est presque réalisable par rapport à ces contraintes.
- La tolérance ϵ définit le niveau de précision souhaité pour la satisfaction des contraintes. Une valeur plus petite de ϵ exigera une satisfaction plus stricte des contraintes.

- ✓ **Satisfaction des Contraintes d'Inégalité** $\max(0, g(x_{k+1})) < \epsilon$:

- Le problème original impose que les contraintes d'inégalité $g_j(x) \leq 0$ soient satisfaites.

La fonction $\max(0, g_j(x_{k+1}))$ évalue la violation de la contrainte d'inégalité.

Si $g_j(x_{k+1}) \leq 0$, alors $\max(0, g_j(x_{k+1})) = 0$, ce qui signifie que la contrainte est satisfaite.

Si $g_j(x_{k+1}) > 0$, alors $\max(0, g_j(x_{k+1})) = g_j(x_{k+1})$, ce qui représente la quantité de violation de la contrainte.

PO sous Contraintes d'inégalité ou mixte

▪ Méthode Lagrangien augmenté

Exemple.

$$\begin{cases} \min f(x, y) = (x - 1)^2 + (y - 2)^2 \\ h(x, y) = x + y - 1 = 0 \\ g(x, y) = x - 0.5 \leq 0 \end{cases}$$

$$(1) L_{\rho}(x, \lambda, \mu) =$$

$$f(x) + \lambda^T h(x) + \mu^T g(x) + \frac{\rho}{2} \left[\sum_{i=1}^p (h_i(x))^2 + \sum_{j=1}^m \max(0, g_j(x))^2 \right]$$

$$(2) L(x, \lambda, \mu, \rho) =$$

$$L(x, \lambda, \mu, \rho) = f(x) + \lambda^T h(x) + \frac{\rho}{2} \sum_{i=1}^p (h_i(x))^2 + \frac{\rho}{2} \sum_{j=1}^m \left(\max(0, g_j(x) + \frac{\mu_j}{\rho})^2 - \left(\frac{\mu_j}{\rho} \right)^2 \right)$$

PO sous Contraintes d'inégalité ou mixte

■ Méthode Lagrangien augmenté

E₂

```
# Méthode ALM
def alm_algo(f, h, g, x0, lam0=0.0, mu0=0.0, rho=10.0, tol=1e-6, max_iter=20, verbose=True):
    xk = x0.copy()
    lam = lam0
    mu = mu0
    beta = 1.5
    history = {
        'x': [xk.copy()],
        'f': [f(xk)],
        'L_aug': [L_aug(xk, lam, mu, rho)],
        'h': [h(xk)],
        'g': [g(xk)],
    }
    if verbose:
        print("Itération | x          | y          | lambda     | mu          | h(x)       | g(x)")

    for k in range(max_iter):
        res = minimize(lambda x: L_aug(x, lam, mu, rho), xk, method='BFGS')
        xk = res.x
        h_val = h(xk)
        g_val = g(xk)
        lam = lam + rho * h_val
        mu = max(0, mu + rho * g_val)
        rho = beta*rho

        history['x'].append(xk.copy())
        history['f'].append(f(xk))
        history['L_aug'].append(L_aug(xk, lam, mu, rho))
        history['h'].append(h_val)
        history['g'].append(g_val)

        if verbose:
            print(f"{k+1:9} | {xk[0]:.6f} | {xk[1]:.6f} | {lam:.6f} | {mu:.6f} | {h_val:+.2e} | {g_val:+.2e}")

        if abs(h_val) < tol and max(0, g_val) < tol:
            break

    return xk, history
```

PO sous Contraintes d'inégalité ou mixte

■ Méthode Lagrangien augmenté

Exemple.
$$\begin{cases} \min f(x,y) = (x-1)^2 + (y-2)^2 \\ h(x,y) = x + y - 1 = 0 \\ g(x,y) = x - 0.5 \leq 0 \end{cases}$$

```
# Lagrangien augmenté version 1
```

```
def L_aug(x, lam, mu, rho):  
    h_val = h(x)  
    g_val = g(x)  
    penalty_eq = lam * h_val + (rho / 2) * h_val**2  
    penalty_ineq = mu * g_val + (rho / 2) * (max(0, g_val)**2)  
    return f(x) + penalty_eq + penalty_ineq
```

```
# Fonction objective
```

```
def f(x):  
    return (x[0] - 1)**2 + (x[1] - 2)**2
```

```
# Contraintes
```

```
def h(x):  
    return x[0] + x[1] - 1 # égalité : x + y = 1
```

```
def g(x):  
    return x[0] - 0.5 # inégalité : x <= 0.5
```

```
# Lagrangien augmenté version robuste
```

```
def L_aug(x, lam, mu, rho):  
    h_val = h(x)  
    g_val = g(x)  
    penalty_eq = lam * h_val + (rho / 2) * h_val**2  
    # Terme pour l'inégalité (version 2)  
    if g_val + mu/rho > 0:  
        penalty_ineq = (rho/2)*(g_val + mu/rho)**2 - (mu**2)/(2*rho)  
    else:  
        penalty_ineq = -(mu**2)/(2*rho)  
  
    return f(x) + penalty_eq + penalty_ineq
```

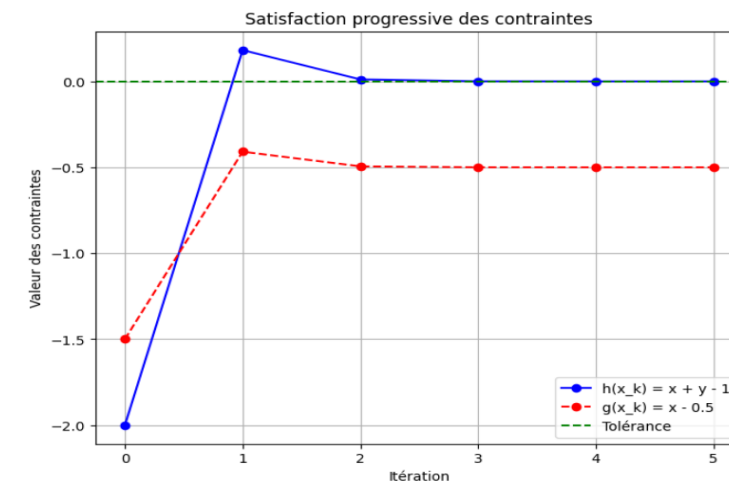
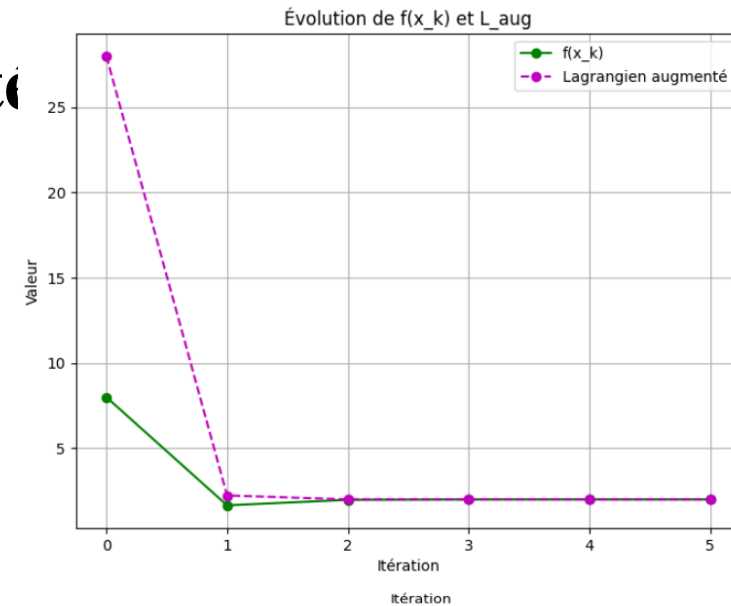
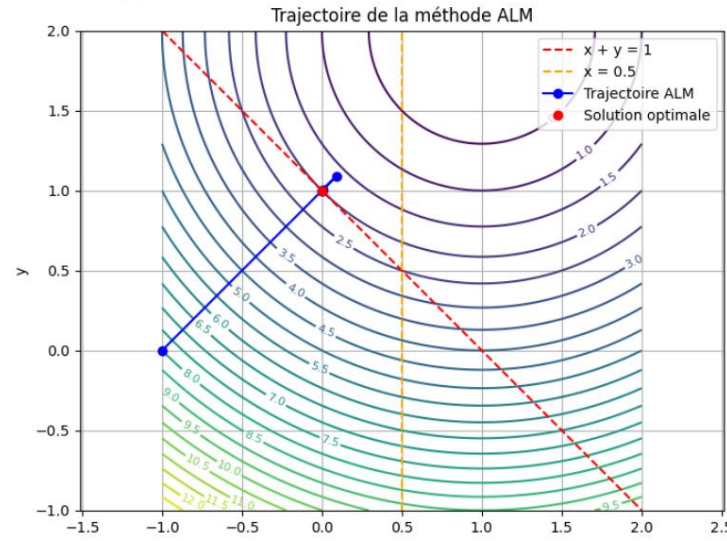
PO sous Contraintes d'inégalité ou mixte

■ Méthode Lagrangien augmenté

Exemple.
$$\begin{cases} \min f(x,y) = (x-1)^2 + (y-2)^2 \\ h(x,y) = x + y - 1 = 0 \\ g(x,y) = x - 0.5 \leq 0 \end{cases}$$

Itération	x	y	lambda	mu	h(x)	g(x)
1	0.090909	1.090909	1.818182	0.000000	+1.82e-01	-4.09e-01
2	0.005682	1.005682	1.988636	0.000000	+1.14e-02	-4.94e-01
3	0.000242	1.000242	1.999516	0.000000	+4.84e-04	-5.00e-01
4	0.000007	1.000007	1.999986	0.000000	+1.39e-05	-5.00e-01
5	0.000000	1.000000	1.999999	0.000000	+2.67e-07	-5.00e-01

Minimum trouvé :
 $x = 0.000000$, $y = 1.000000$
 $f(x, y) = 1.999999$



PO sous Contraintes d'inégalité ou mixte

■ Méthode Lagrangien augmenté

- **Avantage :**

- ✓ Gestion des contraintes complexes : Combine pénalisation quadratique et multiplicateurs de Lagrange pour traiter égalités/inégalités.
- ✓ Bien adapté aux Problèmes non linéaires.
- ✓ Convergence théorique solide et plus rapide que les pénalisations pures
- ✓ utilisé dans l'optimisation sous contraintes en ingénierie, machine learning.
- ✓ Moins sensible que la méthode de pénalisation pure (quadratique) où des valeurs énormes de pénalité peuvent rendre la fonction mal conditionnée.

- **Inconvénient :**

- ✓ Chaque itération demande de résoudre un sous-problème non contraint via une méthode numérique classique
- ✓ Sensibilité au choix des paramètres ρ , β : Si ρ est trop grand le problème devient mal conditionné.
- ✓ Peut converger vers des minima locaux si $f(x)$ ou les contraintes sont non convexes.